

光度立体视觉实验报告

1 任务 1：朗伯反射模型与最小二乘法实现

1.1 实现思路与方法

本任务基于经典的朗伯反射模型。对于物体表面一点，其观测亮度 I 与光源方向 $\mathbf{L}$ 、表面法线 $\mathbf{n}$ 以及反照率 ρ 的关系满足：

$$I = \rho(\mathbf{L} \cdot \mathbf{n}) = \mathbf{L} \cdot \mathbf{g} \quad (1)$$

其中 $\mathbf{g} = \rho\mathbf{n}$ 。对于多个光源 ($k \geq 3$)，我们建立超定方程 $\mathbf{i} = \mathbf{L}\mathbf{g}$ 。通过最小二乘法求解 $\mathbf{g}$ ：

$$\mathbf{g} = (\mathbf{L}^\top \mathbf{L})^{-1} \mathbf{L}^\top \mathbf{i} \quad (2)$$

最后通过归一化得到法线 $\mathbf{n} = \frac{\mathbf{g}}{\|\mathbf{g}\|}$ 。

1.2 实现细节

1.2.1 数学模型与求解逻辑

代码核心逻辑遵循线性最小二乘求解过程。

- 伪逆计算：**为了提高计算效率，程序使用 `np.linalg.pinv(lights)` 预先计算光源矩阵的伪逆 $((\mathbf{L}^\top \mathbf{L})^{-1} \mathbf{L}^\top)$ 。这使得后续对数百万像素点的求解简化为一次矩阵点积运算 $\mathbf{g} = \mathbf{L}_{inv} \cdot \mathbf{I}$ 。

1.2.2 数据预处理与加载

程序能够处理不同格式的数据集：

- 亮度归一化：**读取图像时，通过 `img.astype(np.float32) / 255.0` 将 8-bit 像素值映射至 $[0, 1.0]$ 浮点区间。
- 光源解析：**使用 `np.loadtxt` 读取光照向量，并设置 `skiprows=1` 以自动跳过文件头部的数量标识行。

- **参数化接口**：利用 `argparse` 模块实现了命令行接口，可以通过 `--name` 参数动态指定待处理的物体名称（如 `cat`, `horse` 等），便于批量化测试。

1.2.3 计算效率优化策略

针对图像处理中常见的计算瓶颈，代码采用了掩模驱动的矩阵化运算：

- **空间压缩**：程序首先通过 `mask.reshape(-1)` 将二维图像展平，随后利用 `np.where(mask_flat > 0)` 提取物体区域的索引。
- **加速**：仅针对掩模内部的有效像素进行矩阵运算，避免了对背景区域的无效计算。


1.2.4 可视化映射与图像保存

为了生成符合人类视觉感官且满足作业要求的法线贴图，代码执行了以下转换：


- **颜色映射**：采用公式 $V = \text{uint8}((N + 1.0) \times 128)$ 。其中 n_x, n_y, n_z 分别对应 RGB 颜色通道。
- **数值截断**：使用 `.clip(0, 255)` 确保浮点计算后的数值严格落在有效图像像素范围内，防止溢出。
- **色彩空间转换**：由于 OpenCV 的 `cv2.imwrite` 函数遵循 BGR 存储标准，而计算过程中使用 RGB 逻辑，因此在保存前调用 `cv2.cvtColor(vis_map_rgb, cv2.COLOR_RGB2BGR)` 进行通道交换，确保法线图中指向相机的 z 分量呈现正确的蓝色调。

1.3 实验结果展示


以下展示了附件中 5 组数据的法线图计算结果：



(a) Cat



(b) Owl



(c) Horse



(d) buddha



(e) Sheep

2 任务 2: DiLiGenT 数据集测试与性能分析


2.1 实现

针对 DiLiGenT 数据集，实现中考虑了以下两点：

1. **光强归一化**：读取 `light_intensities.txt`，将每张图像除以对应光源的强度，消除光源亮度不一的影响。
2. **16-bit 数据处理**：图像读入后除以 65535。

2.2 实验结果展示

以下展示了 10 组数据的法线图计算结果：




(a) Ball

(b) Bear

(c) Buddha

(d) Cat

(e) Cow



(f) Goblet

(g) Harvest

(h) Pot1

(i) Pot2

(j) Reading

2.3 实验结果与误差统计

使用最小二乘法在 DiLiGenT 数据集上的平均角度误差如下表：

表 1: 任务 2 统计表 (单位：度)

物体	Ball	Bear	Buddha	Cat	Cow
平均 angular error	4.38	8.97	15.46	8.47	25.64
物体	Goblet	Harvest	Pot1	Pot2	Reading
平均 angular error	18.80	30.62	9.31	15.52	18.81

2.4 分析与讨论

通过对比不同物体的结果，可以观察到：

1. **材质影响**：Ball 的误差最小 (4.38°)，因为它极其接近理想的朗伯体。而 Pot2 等具有金属质感的物体误差较大，这是因为产生了镜面高光，违反了朗伯假设。

2. **几何复杂度**：Harvest 和 Cow 结构复杂，产生了大量的自我遮挡阴影)。在阴影区域，亮度接近 0，最小二乘法会将此类“离群点”错误拟合，导致法线方向偏离。


3 任务 3：Thresholding 算法

3.1 算法描述

实现了一种基于排序的方法。对于每个像素，对其 96 个观测值按亮度排序，剔除最暗的（疑似阴影）和最亮的（疑似高光）观测，仅利用中间段的“稳定”数据进行求解。在实现过程中，最初使用设定阈值的方案，但是效果提升并不明显，因此参考原论文使用了排序后按比例进行剔除的方法，最终参数设定为 40%-60%。

3.2 实验结果展示

以下展示了 10 组数据的法线图计算结果：




(a) Ball

(b) Bear

(c) Buddha

(d) Cat

(e) Cow



(f) Goblet

(g) Harvest

(h) Pot1

(i) Pot2

(j) Reading

3.3 结果对比与分析

对比任务 2（全光源）与任务 3（带阈值筛选）的结果：

表 2: 任务 2 与任务 3 MAE 对比

物体	任务 2 平均 angular error	任务 3 平均 angular error(Tlow=0.4, Thigh=0.6)	改进情况
Ball	4.38	1.93	↓ 55.9%
Bear	8.97	10.08	↑ 12.4%
Buddha	15.46	11.19	↓ 27.6%
Cat	8.47	6.77	↓ 20.1%
Cow	25.64	15.15	↓ 40.9%
Goblet	18.80	12.77	↓ 32.1%
Harvest	30.62	22.30	↓ 27.2%
Pot1	9.31	7.65	↓ 17.8%
Pot2	15.52	11.19	↓ 27.9%
Reading	18.81	14.19	↓ 24.6%

分析：

- 阴影剔除：**通过设定下界阈值，去除了遮挡导致的低亮度噪声，使得法线不再向远离光源的方向偏移。
- 高光剔除：**通过设定上界阈值，去除了非朗伯反射的极高亮区域。
- 数据质量与冗余性的权衡：**实验结果显示，任务 3 仅利用了约 20% 的图像数据，却在多数物体上取得了远优于全光源计算的精度。这证明了在存在非朗伯干扰时，高质量的局部观测比低质量的全局冗余数据更具价值。
- 对 Bear 异常情况的思考：**Bear 是实验中唯一误差上升的物体（从 8.97 升至 10.08）。分析认为，该物体表面材质更接近理想朗伯体且反射率较低，此时任务 2 通过 96 张图的平均效应有效抑制了相机传感器的随机噪声；而任务 3 的严苛筛选导致参与计算的样本量过小，放大了噪声对法线求解的影响。
- 位置阈值法的自适应优势：**对于 Cow 和 Harvest 等具有复杂凹陷结构的物体，其分别下降了 40.9% 和 27.2%。这得益于 Position Thresholding 的自适应特性：它不依赖绝对亮度，在复杂的阴影区域依然能提取出有效的法线信息。

总结：Thresholding 算法显著提升了复杂材质和复杂结构物体的重建精度。但在图像点数较少时，若剔除过多点，可能导致最小二乘法对噪声敏感。


4 Bonus：深度学习方法 PS-FCN 性能评估

4.1 PS-FCN 模型简述

PS-FCN (A Flexible Learning Framework for Photometric Stereo) 是能够处理任意数量光源输入且针对非朗伯体反射设计的深度全卷积网络。与传统方法不同，它通过学习物体表面的特征表示，自动识别并忽略阴影与高光干扰，从而获得更精确的法线估计。

4.2 实验结果展示


以下展示了 PS-FCN 在 DiLiGenT 数据集上的法线图计算结果：




(a) Ball




(b) Bear




(c) Buddha



(d) Cat




(e) Cow




(f) Goblet




(g) Harvest



(h) Pot1




(i) Pot2



(j) Reading

以下是它在附件 5 组数据中的结果



(a) Buddha

(b) cat

(c) horse

(d) owl



(e) sheep



(f) 绘制的球体 Normal map

4.3 DiLiGenT 数据集定量分析

在 DiLiGenT 数据集的 10 个物体上，PS-FCN 表现出了极强的鲁棒性。实验结果统计如下：

表 3: PS-FCN 与任务 2 平均 angular error 对比 (度)

物体索引	1	2	3	4	5	6
PS-FCN	2.82	7.55	7.91	6.16	7.33	8.60
Task 1	4.38	8.97	15.46	8.47	25.64	18.80
物体索引	7	8	9	10	平均	
PS-FCN	15.85	7.12	7.25	13.33	8.39	
Task 1	30.62	9.31	15.52	18.81	15.59	

对比结论： PS-FCN 在 DiLiGenT 上的平均误差从 15.59 降至 8.39。特别是在 Harvest (从 30.62 降至 15.85) 和 Cow (从 25.64 降至 7.33) 等复杂几何体上，深度学习方法几乎解决了传统方法无法处理的严重阴影与镜面反射问题。

4.4 附件数据定性分析与讨论

在对附件提供的 5 组 8-bit 数据进行测试时，PS-FCN 平均 angular error 均在 70° 左右，不过这大概是因为只提供了一个球体的 normal map 做参考。定性分析后可以发现，Buddha、Horse 等物体表面法向连续性较好，大面积区域颜色过渡自然，相比传统方法更加平滑。但同时，Cat、Sheep 等物体细节更加不明显，法向变化偏保守，传统方法细节更加全面。

综合比较两种方法可以发现，从整体几何一致性和视觉合理性来看，PS-FCN 模型整体结果更加合理，但是在细节捕捉上仍可以提升。

4.5 改进建议

改进方案： 1. **增强特征提取能力：** PS-FCN 原本采用标准卷积结构处理多光照输入，可以考虑引入残差网络或 DenseNet 模块，提高深层特征表达能力。对于表面法线的微小差异，深层特征网络更容易捕捉。

2. **光照扰动增强：** 训练时加入光照强度、方向的小扰动，或者模拟不同光源组合，提高模型对光照变化的鲁棒性